И.И. Ахмеров
ИТМО

Домашнее задание

Efficient NN

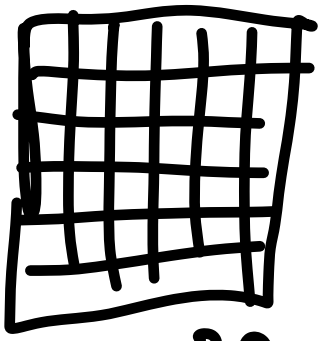
CNN Model:

	c_i	c_o	k	s	p
Conv:	3	32	7	2	3
BatchNorm:	32				
ReLU:					
Conv:	32	64	5	2	
BatchNorm:	64				
ReLU:					
Conv:	64	128	3	2	1
ReLU:					
Conv:	128	256	1		
ReLU:					
Conv:	256	256	3	2	1
BatchNorm:	256				
ReLU:					
Conv:	256	512	1		
BatchNorm:	512				
ReLU:					
GAP:	1:1				
Flatten:					
Linear:	512	256			
ReLU:					
Linear:	256	100			

FLOPs

Пример подсчета:

image



32×32

ядро 7×7

32 канала

stride 2

padding 3

1) ядро 7×7:

Умножения: каждый с каждым

7×7=49

Сложения: между внутренними параметрами

48

Суммарно 49+48 flops= $\underset{M}{\overset{\Delta}{97}} \Rightarrow 48$

Для ядра N×N flops= N·N·2-1=

$= 2N^2 - 1$

2) ядро 7×7 32 канала

$97 \cdot 32 = \times \begin{array}{r} 97 \\ 32 \\ \hline 194 \\ 291 \\ \hline 3104 \end{array}$ flops | Значит $\cdot C \cdot 2N^2 - 1$

3) ядро 7×7 32 канала

32×32 imgs2

Кол-во проходов сверткой по изображению: $32 - 7 + 1 = 26$ в одну сторону, в обе $26 \cdot 26$

Значит: $(imgs2 - K + 1)^2$

4) $(32 - 7 + 1)^2 \cdot (C \cdot 2N^2 - 1)$ ядра 7×7, 32 канала

32 imgs4 $(I - N + 1)^2 \cdot (2CN - 1)$ stride 2

$$flops = \left(\frac{(I - K)}{2} + 1\right)^2 \cdot (2CN^2 - 1)$$

5) ядро 7×7 32C

T 32 S 2 паддинг 3

$$flops = \left(\frac{(I + 2 \cdot 3 - N)}{S} + 1\right)^2 \cdot$$

$$\cdot (2 C N^2 - 1)$$

Для этого ядра:

$$flops = \left(\frac{(I + 2P - N)}{S} + 1\right)^2 \times$$

$$\times (2 C_{in} C_o N^2 - 1)$$

с битами умножаем на размер B

ReLU: max(0, x) · значит $flops = B C_o N_o$

MaxPool: K 3 S 2 P 1

та же самая свертка, но из операций только сравнения

$$flops = C(K^2-1)\left(\left(\frac{I+2P-K}{S}\right)+1\right)^2$$

BatchNorm2d: NM 64

$$\left(\frac{x-\mu}{std}\right)\gamma+\beta \cdot 4 \text{ flops}$$

GlobalPool2d (1,1):

среднее по всем, для $I=32$

I^2 flops

Linear: $2I$ flops

Получилось вывести формулу flops для нашей модели. посчитаем суммарно:

$$CNN: \left(\frac{(I+2P-N)}{S}+1\right)^2 \times$$

$$\times (2C_{in}C_0N^2-1)$$

$$ReLU: flops = BC_0N_0$$

$$MaxPool2d: C(K^2-1)\left(\frac{I+2P-K}{S}+1\right)^2$$

$$BatchNorm2d: 4CI^2$$

$$GlobalPool2d: CI^2$$

$$Linear: 2OI$$

CNN Model:

	c_i	c_o	k	s	p
C:	3	32	7	2	3
BN:	32				
M:	3	2	1		
C:	32	64	5	2	
BN					
RC:	64	128	3	2	1
C:	128	256	1		
RC:	256	256	3	2	1
BN					
RC:	256	512	1		
BN					
R					
GA:	1:1				
FL:	512	256			
RL:	256	100			

Посчитать Flops для не заданных I и B с условием 1 MAC = 2 Flops

$$Flops(I,B) = B(17775I^2 + 313600)$$

Memory

В FP32 каждый элемент занимает 32 бита <=> 4 байта.

То есть вход $4 \cdot C \cdot T^2$

```
CNN Model:
    C_i C_o K S P
C:  3  32  7 2 3
BR
M:  3 2 1
C:  32 64 5    2
B
R
C:  64 128  3 2 1
RC: 128 256 1
BC: 256 256 3 2 1
B
R
C: 256 512 1
B
R
GA: 1:1
F
L: 512 256
R
L: 256 100
```

Память

$4BT^2CK^2$

На каждом слое хранится вход и выход

	Input	Output	All
C_1	$3BI^2$	$8BI^2$	$11BI^2$
M	$8BI^2*3$ (+)	2 bias	$8BI^2$
		$4BI^2C K^2$	$9BI^2$
C_2	$5BI^2$	$4BI^2$	
BN	$7BI^2$	$4BI^2$	$11BI^2$
C_3	$7BI^2$	$2BI^2$	$9BI^2$
C_4	5	4	9
C_5	7	1	8
BN	4	1	5
C_6	4	2	6
BN	5	2	7

GAP 5 512B 5*512

L_1 3*512 256B 3*256

L_2 3*256 100 3*356

Пиксель MaxPool2d - $13BT^2$

Memory(B, T) = $13BT^2 \cdot 4 +$

+ память модели = 4174632 + $53BT^2$

UPP: нужна сумма

сумма по слоям $4(33BT^2 + 868B) +$

+ память модели

Latency

Нужно знать сколько читать из памяти это input и output + веса модели

Введем BytesMoved(I, B) =

= Bytes input + weights + output по всем слоям

$$Latency = B_0 + \max(F(I,\Theta), BM(I,B))$$

Energy

$$E(B,I,\Theta) = \theta L + \partial F + \theta BM$$

Сетка параметров и эксперименты

GPU RTX 5060Ti 16gb

Сетка параметров описана в коде. OOM произошел на

I 1024 B 512